Pentaho. Conectando a MySQL

Big Data Apiicado 03/12/23 – IES Fernando Wirtz Rafael Chamorro Maceiras

Fecha	Motivo del cambio
	Versión inicial

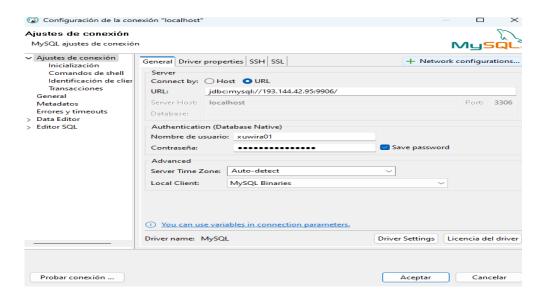
Índice

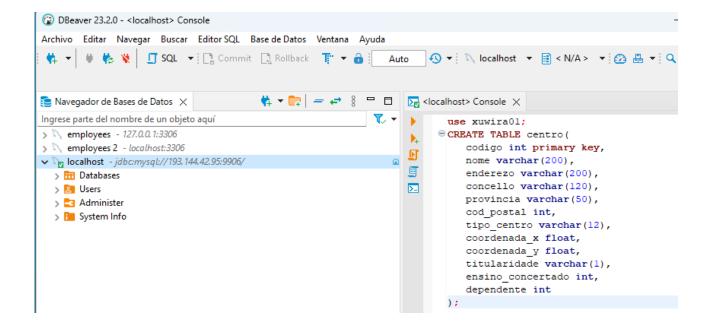
Pentaho. Conectando con MySQL	2
Crear la BD	2
Crear la transformación en Pentaho	3
Archivos de entrada	3
Transformaciones	4
Insertar en la BD xuwira01	5
Ejecutamos la Transformación	
Comprobación desde DBeaver	
Sacando datos de una tabla HTML y limpiarlos	7
Exportar la hoja de cálculo a .csv	7
Abrir el archivo excel	7
Eliminar columnas sin datos	8
Separar el código del nombre del centro	9
Guardamos un archivo .csv	10
Almacenar los datos en la base de datos	11
Sacando datos de un PDF	13
Importando los datos	13
Importando el csv a Pentaho	
Mapeo de valores nulos	15
Importar datos a la BD	15

Pentaho. Conectando con MySQL

Crear la BD

Utilizamos DBeaver para conectar y crear la tabla centro.





Crear la transformación en Pentaho

Archivos de entrada

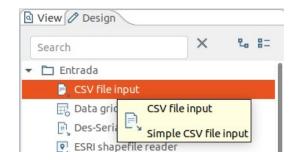
Obtenemos los archivos .csv descargandolos desde la pagina de la xunta.

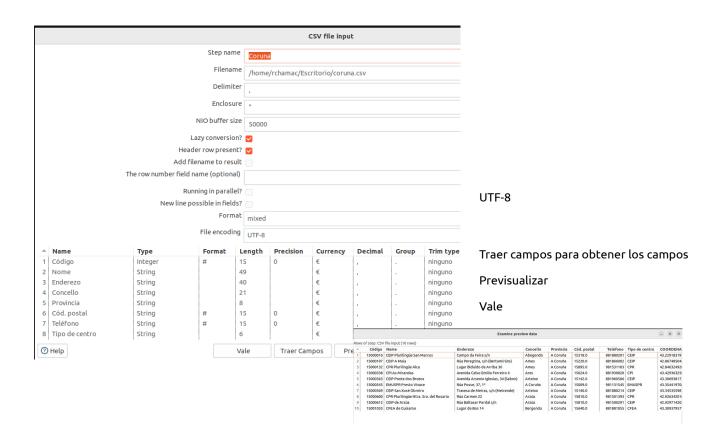


Creamos la transformación en Pentaho.

Como entrada de datos seleccionamos archivo csv, lo hacemos por cada uno de los archivos de datos:

Coruña, Lugo, Orense y Pontevedra





IES Fernando Wirtz 3/18

Transformaciones

Modificar el campo titularidade:

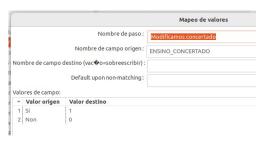
U para público, R para privado



Modificar el campo concertado:

1 para Si

0 para Non



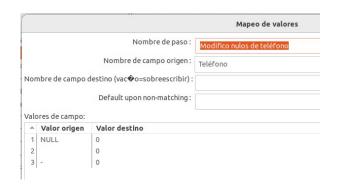
Modificar el campo dependente:

1 para Si

0 para Non



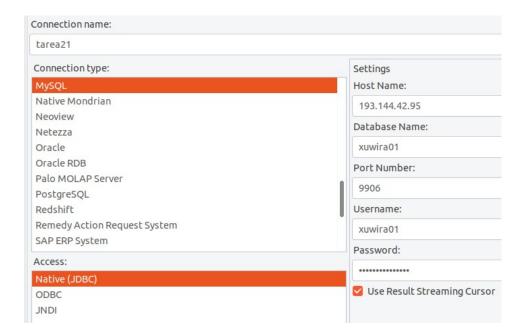
Como el campo teléfono daba errores corrijo los campos nulos o vacíos que pueda tener modificándolos con un '0'

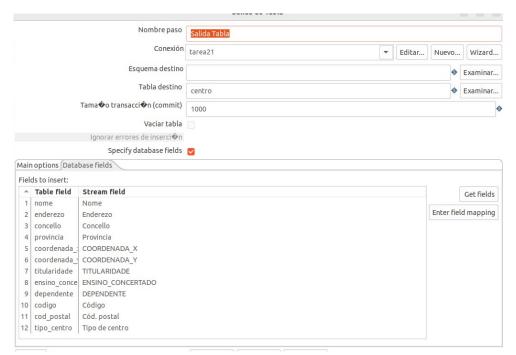


Insertar en la BD xuwira01

Utilizo la opción de Pentaho 'Salida a Tabla'

Configuración de la conexión:



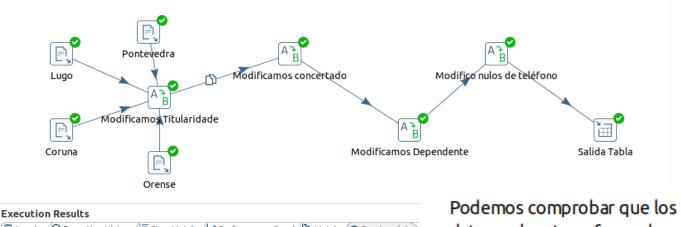


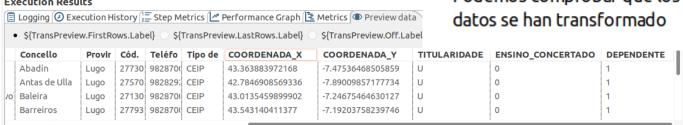
Get fields → para obtener los campos de los datos

Enter field mapping → para indicar a la BD la correspondencia de columnas de los datos

IES Fernando Wirtz 5/18

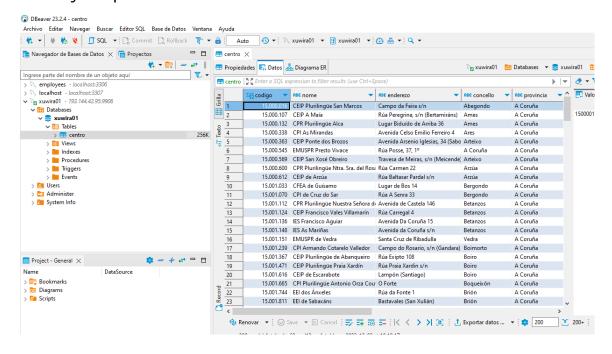
Ejecutamos la Transformación





Comprobación desde DBeaver

Conectamos al servidor y comprobamos los datos en la base de datos Xuwira01:



Sacando datos de una tabla HTML y limpiarlos

Copiamos los datos de la web indicada al archivo sustitutos.xlsx

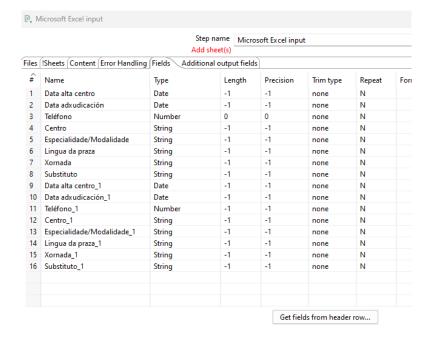
Exportar la hoja de cálculo a .csv

Abrir el archivo excel

En pentaho cargamos el archivo xlsx



En la pestaña 'fields' obtenemos las columnas que tiene el archivo y comprobamos el tipo de dato. Modificamos lo que nos interese.



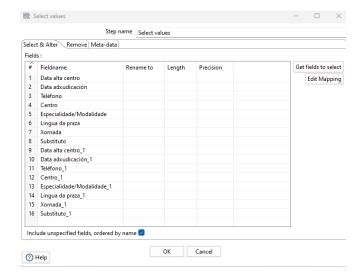
IES Fernando Wirtz 7/18

Eliminar columnas sin datos

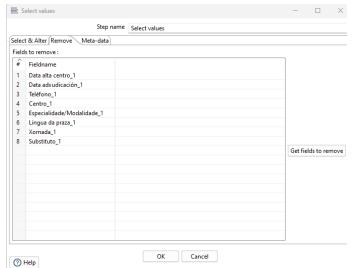
Utilizo una transformación 'Select Values' para quedarme con las columnas que me interesan, y borramos las que no tienen datos



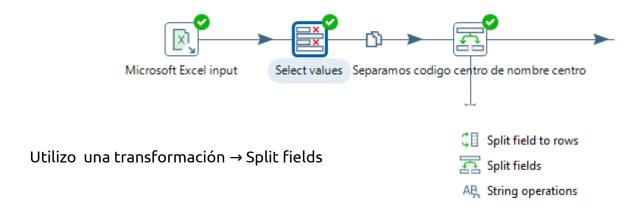
En la pestaña 'Select' obtenemos todas las columnas



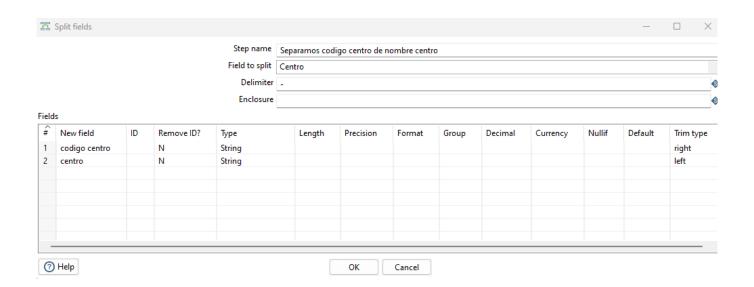
En la pestaña 'Remove' indico las columnas que voy a borrar



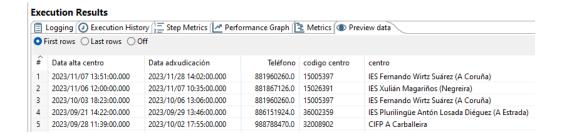
Separar el código del nombre del centro



De la columna centro utilizamos el delimitador '-' para crear dos nuevas columnas 'código centro' y 'centro' también borramos los espacios



Resultado tras la ejecución

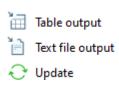


IES Fernando Wirtz 9/18

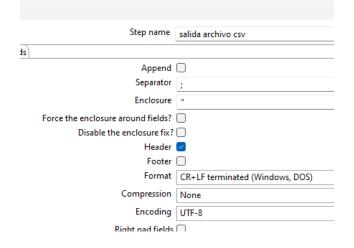
Guardamos un archivo .csv

Seleccionamos salida a archivo de texto

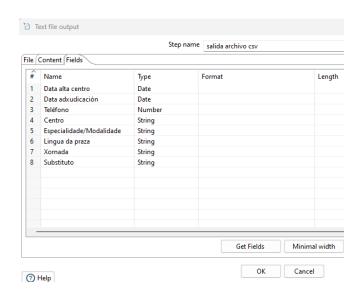




En contenido especificamos la codificación UTF-8



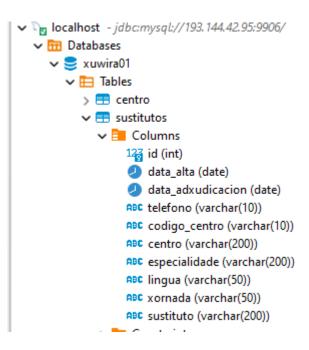
En la pestaña 'fields' seleccionamos las columnas que queremos pasar al archivo .csv



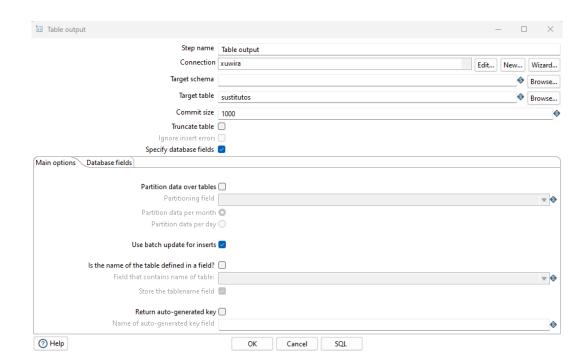
Almacenar los datos en la base de datos

Desde Dbeaver creamos la tabla en la base de datos xuwira01

```
© CREATE TABLE sustitutos (
   id int primary key auto_increment,
   data_alta date,
   data_adxudicacion date,
   telefono varchar(10),
   codigo_centro varchar(10),
   centro varchar(200),
   especialidade varchar(200),
   lingua varchar(50),
   xornada varchar(50),
   sustituto varchar(200)
);
```

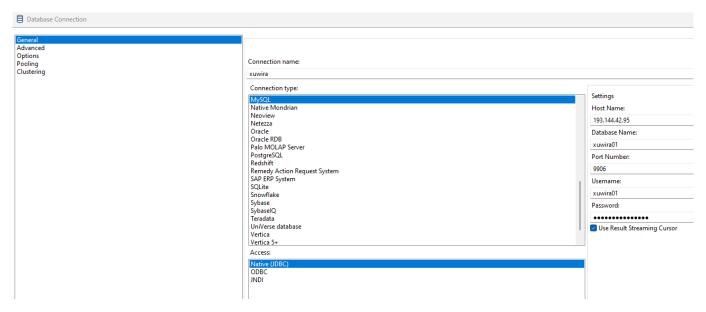


En Pentaho → salida seleccionamos salida a tabla



IES Fernando Wirtz

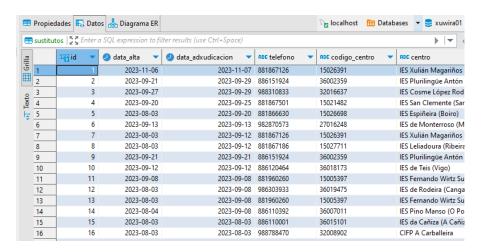
Configuramos la conexión con la BD



Y ejecutamos la transformación:



Comprobamos el resultado con Dbeaber

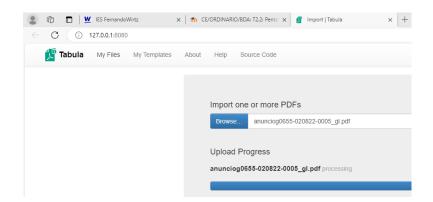


Sacando datos de un PDF

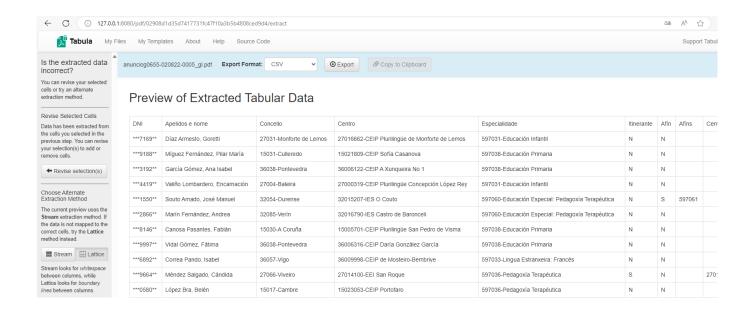
Importando los datos

Utilizaremos el programa tabula para extraer los datos de unas tablas existentes en un pdf.

Abrimos tabula e importamos el pdf

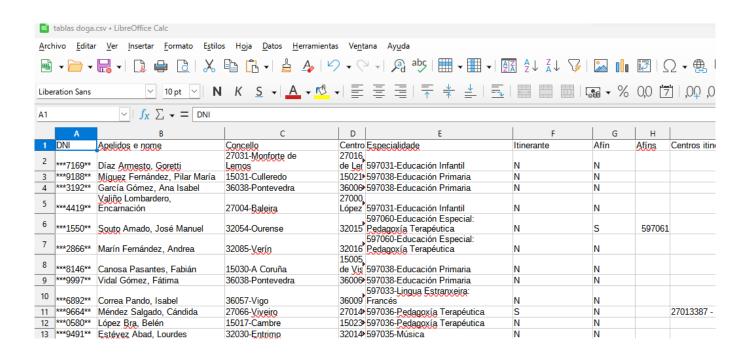


El programa detecta automáticamente las tablas y nos ofrece opciones para la salida de los datos, seleccionamos 'CSV'

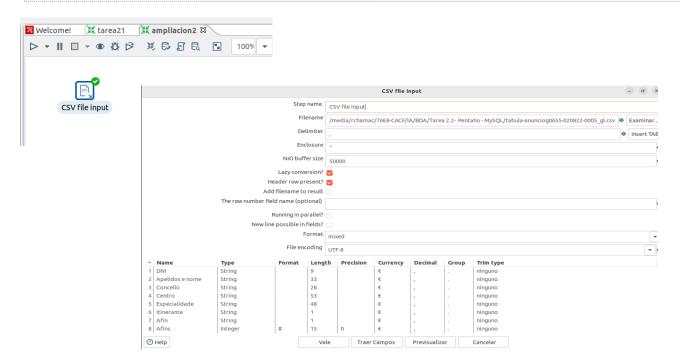


IES Fernando Wirtz

Nos descargamos el .csv resultante



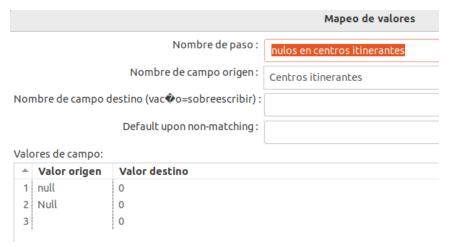
Importando el csv a Pentaho



Mapeo de valores nulos

Mapeamos los campos en los que vemos que hay nulos y ponemos un '0' en su lugar





Importar datos a la BD

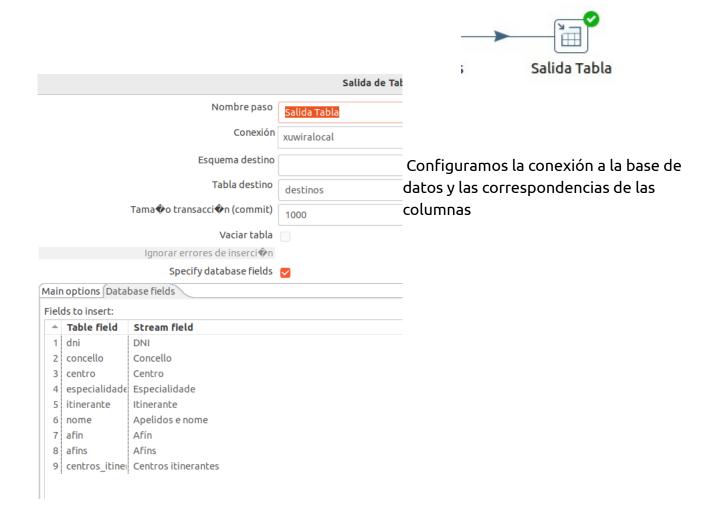
Creamos la tabla destino:

```
GNU nano 6.2 am

CREATE TABLE destinos(
  id int primary key auto_increment,
  dni varchar(12),
  nome varchar(200),
  concello varchar(120),
  centro varchar(200),
  especialidade varchar (100),
  itinerante varchar (4),
  afin varchar(120),
  afins varchar(200),
  centros_itinerantes varchar(200)
);
```

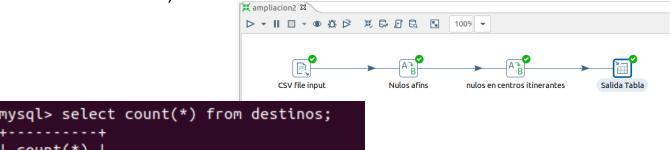
IES Fernando Wirtz 15/18

Configuramos la salida a tabla en Pentaho



Ejecutamos la transformación y comprobamos en la base de datos (en este caso lo hice en una

base de datos en local)



#-----+
| count(*) |
#-----+
| 6496 |
#-----+
1 row in set (0,00 sec)
mysql>

Comprobamos que se insertaron 6496 filas en la tabla